

涉密论文 ☐ 公开论文 ☐

浙 江 大 学

本科生毕业论文



题目 统一多模态模型的重建对齐

姓名与学号 谢集 3220103501

指导教师 魏颖

年级与专业 2022级计算机科学与技术

所在学院 竺可桢学院

递交日期 2026 年 5 月 17 日

浙江大学本科毕业论文（设计）承诺书

1. 本人郑重地承诺所呈交的毕业论文（设计），是在指导教师的指导下严格按照学校和学院有关规定完成的。

2. 本人在毕业论文（设计）中除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得浙江大学或其他教育机构的学位或证书而使用过的材料。

3. 与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

4. 本人承诺在毕业论文（设计）工作过程中没有伪造数据等行为。

5. 若在本毕业论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

6. 本人完全了解浙江大学有权保留并向有关部门或机构送交本论文（设计）的复印件和磁盘，允许本论文（设计）被查阅和借阅。本人授权浙江大学可以将本论文（设计）的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编本论文（设计）。

作者签名：

导师签名：

签字日期：

年 月 日

签字日期

年 月 日

致谢

转眼间四年过去了，浙江大学作为一个平台，见证了一个一无所有却马不停蹄的少年的奋斗。我要感谢 ACM 队的王灿老师和我的队友晨毓、天健，给了我作为队长拿下 ICPC 区域赛金牌的机会；我要感谢我的科研引路人德蔚师兄，后来我才明白，一个愿意教你本领带你读论文的前辈是多么可贵；我要感谢泽川、李右、文松、江泓师兄，在做项目的时候给了我莫大的照顾；我要感谢我在 seed 的 mentor 王珣，谢谢你对我一直以来的认可和信任，给了我一个顶级实习的机会，一次又一次地包容那个未入社会、不成熟的小孩子；我最感激的还是伯克利的旭东前辈——您赏识我、信任我，给了我伯克利暑研的机会，教会了我科研的原则，带我发出了第一篇独立一作的论文，给了我非常强的推荐信。遇见您是我这辈子最大的荣幸；我要感谢吴飞老师、杨易老师、魏颖老师，是你们的鼓励，坚定了我出国读博、远走高飞的想法。

我尤其需要感谢身边我爱的，和爱我的人们。首先必须感谢我 318/503 的室友得江、浩浩、正宇，大学四年我们几乎没有争吵和矛盾，还创造了无限美好的回忆，谢谢你们第一次给了我第二个家的感觉。在博士申请季，很多浙大的学长学姐给了我很多的建议。感谢林湛、上展、开炫、周炜、宜平、曾充、海岸、光昭、子墨、子宇、帅克、耿晨、夏彦（名字顺序随机的，希望我没有遗漏），没有你们的建议，我不知道要多走多少弯路；感谢北大的宇威、港科大的佳琪两位兄弟申请季一直以来的陪伴、支持和鼓励；感谢伯克利的佳鑫学姐，你的选导建议最终帮我拿到了申请季的唯一一个 offer；感谢 UMich 的思涵、子乔前辈，在我处于焦虑边缘时给我的机会；我尤其想感谢港大的伟阳学长，在申请季给予我太多无私、暖心的帮助，你永远是我的大哥！最后感谢我的父母，你们倾听我的喜与哀，尊重我的每一个选择，是我最坚强的后盾。还有太多太多的朋辈、学弟学妹，我就不一一感谢了！

特别地，我要感谢从未停下前进脚步的自己。我虽不像身边的竺院之光、计院之子一样亮眼，但这并不妨碍我欣赏和爱我自己。我欣赏想把每一件事情做到极致的自己；我欣赏给我爱的人们提供帮助的自己；我欣赏拥有常人不具备直

觉的自己——重建对齐这个 **idea** 从诞生起就没有被理解，就连论文发布后，甚至有很多知名学者都无法理解我的方法为什么有效。不论过去的二十二年我对或做错了多少，曾经有多么不堪，下段旅程我一定要好好爱惜自己。

摘要

统一多模态模型希望在同一框架中同时支持视觉理解与视觉生成，是多模态人工智能的重要发展方向。然而，统一架构并不自动带来统一能力。现有模型在生成训练中仍然较多依赖文本监督，而文本很难完整描述图像中的空间布局、细粒度属性和对象关系。因此，模型虽然可能在理解任务中已经提取到丰富视觉信息，但这些信息未必能被生成路径充分利用，最终表现为属性绑定、空间关系和图像编辑一致性不足。

本文围绕重建对齐（Reconstruction Alignment, RecA）展开研究，核心思想是把模型自身的视觉理解表征作为更密集的条件信号，并通过图像重建目标让生成路径重新学习使用这些表征。本文首先介绍 RecA 的动机、训练目标和实现方式；随后在 Show-o、Janus-Pro、OpenUni、Harmon、MMaDA 和 BAGEL 等不同统一多模态模型上验证其普适性；最后通过可行性消融、OpenUni 机制消融和 Z-Image 非统一多模态实验分析收益来源。实验结果表明，RecA 在多种模型结构上均能带来稳定提升。1.5B 规模模型在 GenEval 上达到 0.86，在 DPGBench 上达到 87.21；结合 GPT-4o-Image 数据后进一步达到 0.90 和 88.15。在图像编辑任务中，BAGEL 加入 RecA 后也能提升主体保持和局部修改效果。

进一步分析显示，RecA 的收益主要来自重建目标提供的密集视觉监督，而非额外训练步数、提示词模板或特定数据来源。OpenUni 上的消融结果说明，中后层理解表征对对象关系和属性绑定更关键；Z-Image 实验进一步表明，即使生成模型本身并非原生统一多模态结构，接入外部视觉表征后也可以通过重建对齐获得可用的视觉条件。本文的研究说明，重建目标可以作为连接理解路径和生成路径的一种有效后训练方式，并为提升统一多模态模型的生成准确性和条件保持能力提供参考。

关键词：统一多模态模型；视觉生成；重建对齐；自监督重建；多模态表征

Abstract

Unified multimodal models aim to support visual understanding and visual generation in one framework. However, a unified architecture does not necessarily mean that understanding representations are effectively used for generation. Current models still rely heavily on sparse text supervision, which cannot fully describe spatial layouts, fine-grained attributes, and object relations. As a result, information already captured by the understanding path may be weakly transferred to the generation path, leading to errors in attribute binding, spatial control, and image editing consistency.

This thesis studies Reconstruction Alignment (RecA), which uses a model’s own visual understanding representations as dense conditions and trains the generation path with an image reconstruction objective. The method is evaluated on Show-o, Janus-Pro, OpenUni, Harmon, MMaDA, and BAGEL. Experiments show consistent gains across architectures. A 1.5B model reaches 0.86 on GenEval and 87.21 on DPGBench, and further improves to 0.90 and 88.15 with GPT-4o-Image data. RecA also improves BAGEL on image editing benchmarks, especially in preserving subjects and local structures. Ablations show that the gains are not simply caused by extra training steps, prompt templates, or a specific data source. OpenUni experiments indicate that middle-to-late understanding layers provide the most useful dense visual supervision. Experiments on Z-Image further show that reconstruction alignment can also make externally attached visual features useful for a non-unified generation model. These results suggest that RecA is an effective post-training method for connecting visual understanding and generation.

Keywords: unified multimodal model; visual generation; reconstruction alignment; self-supervised reconstruction; multimodal representation

目录

1	绪论	1
1.1	研究背景	1
1.2	研究意义	2
1.3	研究内容	2
2	相关工作	5
2.1	统一多模态理解与生成模型	5
2.2	统一模型中的后训练策略	6
2.3	自监督和自改进方法	7
2.4	重建相关方法	8
2.5	多图、视频与高控制生成	8
2.6	多模态评测	9
3	RecA 方法介绍	11
3.1	方法动机	11
3.2	传统训练目标	11
3.3	RecA 的基本流程	12
3.4	总训练目标	14
3.5	为什么重建是有效信号	14
3.6	训练和推理流程	15
3.7	与其他重建方法的区别	15
3.8	本文关注的实现细节	16
4	RecA 的普适性实验	17
4.1	实验目标	17
4.2	基线模型介绍	17
4.3	跨架构普适性	18
4.4	文生图生成结果	19
4.5	图像编辑结果	21

4.6 方法可行性消融实验	24
4.7 实验小结	25
5 RecA 的机制消融实验	27
5.1 分析目标与实验设置	27
5.2 数据规模与提示词模板消融	28
5.3 重建层数范围消融	29
5.4 单层特征重建消融	30
5.5 重建损失与生成指标的关系	32
5.6 非统一多模态模型上的重建对齐	33
5.7 机制小结	35
6 总结与展望	37
6.1 工作总结	37
6.2 不足与展望	37
参考文献	39
附录	43
A 图像生成范式基础	43
B 补充实验可视化	46
作者简历	55
本科生毕业论文（设计）任务书	57
本科生毕业论文（设计）考核	59

1 绪论

1.1 研究背景

近年来，随着深度学习、大规模数据与生成式人工智能技术的发展，文本到图像生成（Text-to-Image, T2I）模型和多模态理解模型都取得了快速进展。但在长期实践中，理解与生成通常处于解耦范式：一个模型负责理解图像，另一个模型负责生成图像，二者通过外部接口协同。从 2024 年起，统一多模态模型（Unified Multimodal Model, UMM）逐渐成为多模态智能研究的重要方向^[1]。与传统上繁杂的“专家系统”不同，UMM 希望在同一模型框架中同时支持图像理解、视觉问答、T2I、图像编辑以及更复杂的跨模态推理任务，并进一步实现理解与生成之间的相互促进^[2-6]。

现有 UMM 通常通过共享架构、共享表征空间、统一词元（token）序列建模或混合理解与生成模块等方式，将文本、图像等不同模态的信息映射到可联合处理的模型内部空间中^[2,4,7-9]。相关研究表明，这类方法已经能够在图像生成、视觉问答、图像编辑和多模态推理等任务中取得较好的性能表现，也能在数据配比层面观察到理解与生成之间的互补关系^[5-6,10-12]。

然而，从训练机制和表征利用的角度看，现有方法仍然存在明显局限。许多 UMM 更像是理解损失和生成损失的并置，而尚未实现真正意义上的表征统一。模型内部通常同时存在理解路径和生成路径：理解路径侧重从多模态输入中抽取语义信息，生成路径则侧重在条件约束下进行分布建模和内容合成。两类路径在优化目标、表征粒度和信息需求上存在天然差异，导致理解表征无法被生成过程充分利用，生成侧表征也不一定能进一步优化理解能力。已有研究也表明，统一模型内部负责生成和理解的视觉编码路径有时需要显式解耦，否则两类任务会互相牵制^[1,3,9,13]。

这种表征失配会直接限制统一多模态模型在高保真生成、复杂图像编辑、多实例组合和跨模态泛化任务中的能力上限^[12,14-15]。因此，如何使模型在理解阶段获得的结构化视觉表征更有效地指导生成过程，是提升统一多模态模型可靠性

和通用性的关键问题。

1.2 研究意义

针对上述问题，近期研究开始探索在生成过程中引入更加丰富和结构化的条件信号。本文关注的重建对齐（Reconstruction Alignment, RecA）方法从“模型应当能够生成其已经理解的内容”这一假设出发，利用视觉理解模块提取的表征作为密集条件，引导生成模块进行语义重建，从而增强生成过程的指令跟随能力^[14]。实验现象表明，理解阶段得到的表征可以用于优化生成模型，并显著改善生成模型的指令跟随能力^[14,16-19]。这说明“理解帮助生成”并非只是一种直觉，但其内部机制、性能提升的本质来源以及跨模态扩展能力仍需要进一步分析。

因此，本文关注统一多模态模型中「重建对齐」的机制问题，试图从表征学习和多模态对齐的角度分析：生成性能提升究竟来自哪一类表征空间；不同层级理解表征在生成过程中的作用是否存在差异；当模型本身并非原生统一多模态结构时，外部视觉表征是否仍能通过重建目标转化为可用的生成条件。

该研究具有两方面意义。首先，在方法层面，理解和生成路径的有效对齐有助于缓解生成模型中常见的结构不一致、属性混淆和语义偏离问题，从而提升统一模型在实际应用中的可控性^[14-15]。其次，在机制层面，对不同层级表征作用的分析能够增强统一多模态模型的可解释性，为后续模型结构设计、训练目标选择和跨模态扩展提供依据^[1,20]。

1.3 研究内容

围绕统一多模态模型中的理解生成对齐问题，本文主要开展以下研究：

1. **理解表征对生成路径的作用机制分析：**通过层级消融、训练目标对比和重建损失分析，研究模型不同层级隐藏状态对生成质量、结构保持和语义一致性的影响。
2. **基于重建的对齐方法整理与实现：**围绕 RecA 等自监督重建对齐思想，梳

理其训练目标、输入条件构造和后训练流程，并讨论其在统一模型中的适用条件。

3. **非统一多模态模型上的扩展分析：**进一步分析当生成模型本身不是原生图像输入模型时，外部视觉表征是否仍能通过重建对齐转化为可用的生成条件。
4. **实验评估与结果分析：**结合生成质量、组合生成能力和机制消融指标，设计实验方案，对不同对齐策略的效果和局限进行分析。

2 相关工作

2.1 统一多模态理解与生成模型

统一多模态理解与生成模型想解决的核心问题，是让同一个模型既能理解图像，也能生成图像。传统做法通常会把理解模型和生成模型分开训练，再通过外部接口把它们连接起来。这种方式实现上比较直接，但两个模型之间的表征并不一定一致，理解模型提取到的信息也不一定能被生成模型完整利用。因此，越来越多工作开始尝试把理解和生成放到统一框架中建模^[1]。

从技术路线看，统一模型大体可以分为几类。第一类是共享表示或共享语义空间的方法。对比语言图像预训练（Contrastive Language-Image Pre-training, CLIP）通过图文对比学习获得了可用自然语言索引的视觉语义嵌入，推动了零样本迁移和跨模态检索的发展^[7]。这类表征可以作为理解侧的语义锚点，但它本身更偏向高层语义压缩，缺少足够的可逆细节，直接用于生成时往往还需要额外的生成头或重建模块补足空间和纹理信息^[1,7]。

第二类是自回归（Autoregressive, AR）或离散视觉词元（token）路线。ImageGPT 证明了从像素出发做生成式预训练也能学到可迁移视觉表征，DALL-E 则进一步把文本 token 和离散图像 token 放到同一个 AR 序列中统一预测^[21-22]。这一路线的优势是接口统一，文本和图像都可以被看作 token 序列处理；但它也容易受到序列长度、离散化误差和误差累积的影响，图像细节和高分辨率生成仍然比较困难^[1]。

第三类是扩散、流模型以及混合式统一架构。潜空间扩散模型（Latent Diffusion Model, LDM）通过预训练自编码器把扩散过程搬到潜变量（latent）空间，并用交叉注意力（cross-attention）接入文本条件，成为高保真文生图模型的重要基础^[23-24]。Imagen 进一步展示了强文本编码器对生成可控性的帮助^[25]。流匹配（Flow Matching）和校正流（Rectified Flow）则提供了更快、更直接的连续生成路径，为统一理解和生成提供了新的工程可能^[26-28]。

在这些基础上，近期出现了更多混合统一模型。Show-o 在单一变换器（Trans-

former) 中结合 AR 和离散扩散式建模, 使理解、生成和编辑任务能够共享同一个骨干网络^[2]。Show-o2 进一步结合 AR 与流匹配, 并将统一建模扩展到图像和视频场景^[8]。Janus 观察到理解和生成对视觉信息粒度的需求不同, 因此提出解耦视觉编码路径; JanusFlow 则进一步把自回归语言建模与校正流结合^[3,9]。OpenUni 通过轻量连接器 (connector) 连接现成多模态大语言模型 (Multimodal Large Language Model, MLLM) 和扩散模型, 强调低复杂度和可复现^[4]。BAGEL 通过大规模交错图文数据训练统一的纯解码器 (decoder-only) 模型, 强调规模化统一预训练带来的多任务能力^[5]。Harmon 则从共享掩码自回归 (Masked Autoregressive, MAR) 编码器的角度协调理解和生成表征^[6]。

这些工作说明, 统一多模态模型已经不只是一个概念, 而是形成了多条可行路线。但它们也共同暴露出一个问题: 统一架构并不自动带来统一表征。理解任务需要模型捕获类别、关系和语义, 生成任务则需要颜色、布局、纹理和局部结构。当模型把这些目标混在一起训练时, 理解侧得到的信息未必能顺利传递到生成侧, 这也是 RecA 关注的核心问题^[13-15]。

2.2 统一模型中的后训练策略

由于从头训练统一多模态模型成本很高, 后训练策略逐渐成为增强模型生成能力的重要方向。第一类方法是推理时优化, 例如在生成前加入思维链 (Chain-of-Thought, CoT) 推理, 或在生成过程中用外部模型进行逐步验证。这类方法可以提升复杂提示下的生成质量, 但通常依赖外部模型, 不能直接改善 UMM 自身的原生生成能力^[29]。

第二类方法是偏好或奖励优化。基于人类反馈的强化学习 (Reinforcement Learning from Human Feedback, RLHF) 通过人类偏好训练奖励模型, 并用强化学习优化策略, 已经在语言模型指令遵循中得到验证^[30]。基于人工智能反馈的强化学习 (Reinforcement Learning from AI Feedback, RLAIFF) 进一步使用 AI 反馈替代部分人工偏好, 直接偏好优化 (Direct Preference Optimization, DPO) 则把偏好优化转化为更直接的监督式目标^[31-32]。在视觉生成中, 类似的 DPO、组相对

策略优化 (Group Relative Policy Optimization, GRPO) 或奖励优化方法也被用于提升生成策略, 但它们通常需要精心构造的偏好数据和较复杂的训练调参^[33-34]。

第三类方法是利用高质量合成数据进行监督微调 (Supervised Fine-Tuning, SFT)。比如 BLIP3o 等工作使用 GPT-4o-Image 生成大规模图文对, 再对统一模型进行 SFT^[35-36]。这类方法的优点是直接、效果明显, 但代价也很高: 数据生成成本大, 模型可能继承教师模型的偏差, 而且部分基准上还可能出现模板泄露或分布偏移问题^[14]。

RecA 与上述路线的区别在于, 它不依赖外部奖励模型, 也不依赖额外生成的高质量图文对。它只使用无标注图像, 通过模型自身的视觉理解表征构造重建任务。这样一来, 训练信号来自图像本身, 成本更低, 也更适合分析理解表征和生成路径之间的关系^[14]。

2.3 自监督和自改进方法

RecA 也可以放在更广义的自改进 (self-improving) 方法中理解。自训练 (self-training) 或伪标签 (pseudo-labeling) 方法通过教师模型生成伪标签, 再训练学生模型。Noisy Student 是视觉半监督学习中的代表, 它说明模型生成的训练信号可以在迭代中提升模型能力^[37]。Self-Instruct 则在语言模型中利用模型自生成指令数据, 减少人工标注依赖^[38]。

另一类方法更偏向推理期或交互式自我改进。Self-Refine 通过模型对自身输出给出反馈并进行迭代修改, 在不额外训练参数的情况下提升输出质量^[39]。UniRL 在统一多模态模型中利用模型生成图像作为训练数据, 再用理解结果反向监督生成, 形成一种自我改进过程^[40]。

还有一些工作直接围绕理解和生成之间的循环关系设计训练目标。UniCorn 将统一模型拆成提议器 (proposer)、求解器 (solver) 和评判器 (judge), 通过自博弈 (self-play) 和文本到图像再到文本 (Text→Image→Text) 的循环一致性评测来缩小理解生成鸿沟^[13]。GvU 则使用理解分支构造词元级 (token-level) 内在奖励, 通过自监督强化学习优化生成分支^[15]。这些方法和 RecA 的共同点是都尝

试用内部理解能力改善生成；区别在于 RecA 使用更稳定、更直接的图像重建损失，而不是依赖循环一致性或奖励信号。

2.4 重建相关方法

重建长期以来都是视觉表示学习中的重要训练信号。BEiT 和 MAE 通过掩码重建学习视觉表征，证明了重建任务可以帮助模型学习有用的语义结构^[41-42]。不过，这类方法主要关注视觉编码器预训练，目标是得到更强的理解表征，而不是直接提升统一模型的生成路径。

近年来，也有一些工作把重建信号引入多模态模型或生成模型中。部分方法利用预训练扩散模型正则化视觉编码器，以提升视觉理解能力；部分方法从模型中间层隐藏状态重建图像，让理解过程保留更多细粒度信息；还有方法把扩散模型或变分自编码器（Variational Autoencoder, VAE）的隐藏状态与外部视觉编码器对齐^[43-51]。

RecA 和这些方法的关键不同在于，它不是为了单独训练一个更好的视觉编码器，也不是给模型加一个额外的重建头。RecA 直接把 UMM 自身的视觉理解表征作为稠密提示（dense prompt），并把语义层面的图像重建作为后训练目标。它关注的是生成路径能否学会使用理解路径已经提取出的信息，因此更贴近本文关心的理解生成对齐问题^[14]。

2.5 多图、视频与高控制生成

随着统一多模态模型从单图任务走向复杂输入输出场景，多图、视频和高控制生成逐渐成为新的研究重点。UniVideo 将统一建模扩展到视频理解、生成和编辑，采用 MLLM 负责指令理解、多模态扩散 Transformer（Multimodal Diffusion Transformer, MMDiT）负责生成的双流架构，并强调跨任务泛化^[10]。这说明统一模型不仅需要处理静态图像，还需要在时间维度上保持身份、动作和背景一致。

多图和多参考输入则带来了另一个问题：模型必须区分不同参考图中的对象身份和属性。Towards Generalized Multi-Image Editing 提出潜变量分隔符（latent

separators) 和正弦索引编码来区分不同参考图身份^[11]。UniRef-Image-Edit 通过序列化多参考潜变量并结合 SFT 与强化学习 (Reinforcement Learning, RL) 优化多源一致性^[12]。ConsistCompose 则将布局坐标嵌入语言提示, 实现布局可控的多实例组合生成^[52]。

这些工作和本文后续的多图 RecA 扩展直接相关。RecA 能提供每张图像的密集理解表征, 但多图场景还需要解决实例区分和身份绑定问题。因此, 如何把重建对齐与索引编码、图像分隔符或实例级 token 结合, 是本文后续扩展实验需要回答的问题。

2.6 多模态评测

统一多模态模型的评估不能只看单一指标。理解侧需要关注视觉问答、对象识别、关系推理和多模态综合理解能力, 例如流行对象幻觉评估 (Polling-based Object Probing Evaluation, POPE)、多模态评测 (Multimodal Evaluation, MME)、图像问答数据集 (GQA)、多学科多模态理解评测 (Massive Multi-discipline Multimodal Understanding and Reasoning Benchmark, MMMU) 和 SEED 等基准^[53-57]。生成侧则需要关注文本遵循、属性绑定、空间布局和图像质量, 常用基准包括面向对象的生成评测 (GenEval)、细粒度文本图像一致性评测 (DPGBench)、统一图像编辑评测 (ImgEdit) 和通用图像编辑英文评测 (GEdit-Bench-EN)^[16-19]。

因此, 本文后续不仅关注单一生成分数, 也会结合跨模型实验、图像编辑结果和 OpenUni 上的机制消融来判断方法是否有效。这样更有助于回答本文真正关心的问题: 重建对齐的收益是否来自统一模型内部理解表征到生成路径的有效传递, 而不只是某个评测基准上的偶然提升。




图 3.1 统一多模态模型中的理解生成失配示意图。模型在理解任务中能够识别黄色西兰花，但在生成任务中仍可能退化到训练数据中更常见的绿色西兰花。

3 RecA 方法介绍

3.1 方法动机

RecA 的出发点是统一多模态模型已经具备一定的视觉理解能力，但这些理解到的信息并没有被生成路径充分使用。给定输入图像 x 和文本条件 t ，模型会先通过视觉编码器和多模态理解模块得到内部表征 h 。在理解任务中， h 可以用于问答、分类或关系判断；但在生成任务中，模型往往仍然只依赖文本条件 t 。而文本是稀疏的，无法准确描述图片的大量细节，因此，图像中大量细节没有被完整传递到生成过程。

本文希望解决的问题，是让生成路径学会使用理解路径已经提取出来的视觉表征。RecA 试图把模型已经获得的视觉理解信息重新送回生成端，使生成过程不再只依赖稀疏的文本监督。

3.2 传统训练目标

传统统一多模态模型通常会同时包含文本到图像 (Text-to-Image, T2I) 和图像到文本 (Image-to-Text, I2T) 两类训练目标。T2I 目标要求模型根据文本提示生成图像，I2T 目标则要求模型根据图像表征回答问题或生成文本描述。形式上可以写为：




图 3.2 RecA 的方法动机。传统图文对训练主要依赖文本到图像损失，而 RecA 将视觉理解表征作为更密集的条件信号，通过重建目标进行自监督训练。

$$\mathcal{L}_{t2i} = \mathcal{L}(f_{\theta}(t_{\text{prompt}}), I_{\text{gt}}), \quad (3-1)$$

$$\mathcal{L}_{i2t} = \mathcal{L}(f_{\theta}(\text{concat}(t_{\text{question}}, \mathbf{h}_v)), t_{\text{answer}}). \quad (3-2)$$

其中， f_{θ} 表示参数为 θ 的统一多模态模型， t_{prompt} 是生成图像所用的文本提示， I_{gt} 是真实图像， t_{question} 和 t_{answer} 分别表示图像理解任务中的问题和答案， $\mathbf{h}_v$ 表示由视觉理解编码器提取出的图像表征。这里的 $\mathcal{L}(\cdot)$ 可以根据模型类型不同采用不同形式，例如自回归模型中的交叉熵损失，或者扩散模型中的去噪损失。

这个训练范式的问题在于，T2I 主要依赖文本提示。即使文本描述写得很长，也很难完整表达图像中的空间布局、几何结构、局部颜色和物体之间的细粒度关系。也就是说，模型虽然在 I2T 任务中学会了从图像中提取语义表征，但这些表征没有被充分用于 T2I 生成。

3.3 RecA 的基本流程

RecA 的核心做法，是把视觉理解表征当作一种稠密提示 (dense prompt)，用它来替代传统文本提示中缺失的视觉细节。训练流程可以分成三步：第一步，




图 3.3 RecA 的训练流程。方法冻结或部分冻结理解侧模块，将视觉理解编码器得到的表征作为稠密提示，并主要更新生成相关模块，使模型学习根据理解表征重建图像。

使用统一模型的视觉理解路径从输入图像中提取表征。第二步，把该表征和一个重建模板拼接起来，送入生成路径。第三步，要求模型根据这些条件重建原始图像，并用重建损失更新生成相关模块。

设输入图像为 I_{gt} ，视觉理解编码器为 E_u ，则视觉理解表征可以写成：

$$\mathbf{h}_v = E_u(I_{gt}). \quad (3-3)$$

这里的下标 u 表示理解（understanding）。RecA 强调使用理解编码器的表征，而不是生成编码器的底层视觉特征，因为前者更接近语义空间，更容易包含物体类别、属性和关系等高层信息。

随后，模型接收一个模板文本 t_{template} 和视觉表征 $\mathbf{h}_v$ 。模板文本不提供具体图像内容，只用于告诉模型当前任务是根据视觉表征进行图像重建。例如，模板可以类似于“请详细描述这张图像”这一类触发图像重建的提示。RecA 的重建损失定义为：

$$\mathcal{L}_{\text{RecA}} = \mathcal{L}(f_{\theta}(\text{concat}(t_{\text{template}}, \mathbf{h}_v)), I_{gt}). \quad (3-4)$$

这个公式表示：模型根据“模板文本加视觉理解表征”来重建原图，而不再只依赖文本提示生成图像。由于目标图像就是输入图像本身，所以这个过程不需要额外人工标注，也不需要额外生成图文对。



图 3.4 RecA 与统一多模态模型训练流程的结合方式。方法从图像中提取视觉理解表征，将其作为生成路径的条件输入，并通过重建原图来训练生成相关模块。

3.4 总训练目标

在实际后训练中，RecA 可以和原有的 I2T、T2I 目标组合起来。总损失写作：

$$\mathcal{L}_{\text{total}} = \lambda_{\text{RecA}} \mathcal{L}_{\text{RecA}} + \lambda_{i2t} \mathcal{L}_{i2t} + \lambda_{t2i} \mathcal{L}_{t2i}. \quad (3-5)$$

在 RecA 的主要设置中， $\lambda_{\text{RecA}} = 1$ ， $\lambda_{t2i} = 0$ 。也就是说，后训练阶段主要使用重建目标，而不是继续依赖传统文本到图像监督。对于理解和生成共享参数的模型，可以设置 $\lambda_{i2t} = 1$ ，保留一部分图像到文本目标，避免破坏原有理解能力。对于理解和生成模块解耦的模型，则通常设置 $\lambda_{i2t} = 0$ ，并冻结理解部分，只训练生成相关模块。

这一设计使 RecA 的训练信号集中作用在“生成路径如何使用理解表征”这一问题上，而不是重新训练整个模型。这样既降低了训练成本，也让后续消融更容易解释。

3.5 为什么重建是有效信号

重建任务的优势在于监督信号足够密集。文本描述通常只能覆盖图像中的一部分信息，例如主体类别、动作或大致场景，但很难完整描述物体位置、颜色细节、空间关系和背景结构。相比之下，图像重建直接以输入图像为目标，天然包含这些细粒度信息。

从训练角度看，RecA 让模型反复练习一件事：根据理解路径给出的表征恢复图像内容。如果生成路径能够完成这个任务，说明它至少学会了从理解表征

中读取结构信息和视觉细节。这个过程并不需要额外人工标注，因此也适合作为已有统一模型的轻量后训练方法。

这里需要强调的是，RecA 追求语义层面的重建，不追求像素级复制。如果输入给理解编码器的图像分辨率过高，表征中可能会保留过多底层像素细节，模型容易把任务变成普通自编码重建。为了让模型更关注语义信息，RecA 通常会把输入图像缩放到理解编码器允许的较低分辨率。这样得到的表征更像语义提示，而不是完整的像素缓存。

3.6 训练和推理流程

从训练流程看，RecA 可以概括为以下几步：

1. 从无标注图像集合中采样图像 I_{gt} 。
2. 使用视觉理解编码器 E_u 提取图像表征 $\mathbf{h}_v$ 。
3. 将模板文本 t_{template} 与 $\mathbf{h}_v$ 拼接，构造生成路径的输入。
4. 让模型生成或预测图像目标，并通过 $\mathcal{L}_{\text{RecA}}$ 进行后训练。
5. 根据模型结构决定是否冻结理解编码器，以及是否保留 I2T 损失。

推理阶段则保持原模型的使用方式不变。对于文生图任务，用户仍然只输入文本提示；对于图像编辑任务，输入仍然是原始图像和编辑指令。RecA 后训练时使用的视觉理解表征只参与训练，不要求用户在推理时额外提供。这一点说明，RecA 改善的是模型内部生成能力，而不是增加了一个新的外部输入接口。

3.7 与其他重建方法的区别

已有工作中也有不少方法使用“重建”作为训练信号，但 RecA 的目标和用法并不相同。第一类方法会用扩散模型或额外解码器来正则化视觉编码器，重点是提升视觉理解能力。第二类方法会从中间隐藏状态重建图像，用重建作为

理解过程的辅助约束。第三类方法会引入额外对齐模块，把扩散模型或变分自编码器（Variational Autoencoder, VAE）的隐藏状态对齐到外部视觉编码器。

RecA 的不同之处在于，它不以单独训练视觉编码器为目标，也不额外引入重建头。它直接把模型自身的视觉理解表征作为生成条件，把语义层面的图像重建作为 UMM 的后训练目标。整个过程不依赖额外图像描述（caption），也不需要引入辅助模块。因此，**RecA** 更像是对已有统一模型的一次能力校准：让生成路径重新学习如何使用理解路径已经得到的信息。

3.8 本文关注的实现细节

在本文中，**RecA** 不只被看作一个提升指标的方法，还被看作一个可以分析的现象。为了说明它是否真正改善理解生成对齐，后续实验会关注三个实现层面的问题。

第一，**RecA** 是否能迁移到不同结构的统一模型上。如果它只在单一模型上有效，那么它更像是模型特定的调参技巧；如果它能在多个模型上带来一致提升，则说明它可能反映了统一多模态模型中更普遍的理解生成失配问题。

第二，**RecA** 的收益到底来自模型的哪一部分。它可能来自视觉编码器输出，也可能来自中间层语义表征，还可能来自生成头对条件信号的重新适配。这个问题需要通过 OpenUni 上的消融实验进一步分析。

第三，**RecA** 是否只能作用于原生统一多模态模型。本文进一步在 **Z-Image** 这类非统一多模态生成模型上进行分析，观察外部视觉表征在接入生成模型后，是否也能通过重建目标变成可用的生成条件。

4 RecA 的普适性实验

4.1 实验目标

本节主要验证 RecA 是否是一种普适性的提升方法。所谓普适性，指的是它不只在某个特定模型上有效，也能迁移到不同架构、不同视觉分词器或不同生成路径的统一多模态模型上。如果多个模型都出现类似提升，就可以说明 RecA 反映了统一多模态模型中比较普遍的对齐问题，而非某个模型上的偶然现象。

围绕这一目标，本文从三层证据组织实验。第一，先介绍参与比较的基线模型，说明它们分别代表哪些统一多模态架构。第二，比较不同架构在加入 RecA 前后的变化，再在 GenEval、DPGBench 和图像编辑评测基准上报告主要分数，检验 RecA 是否带来稳定提升^[16-19]。第三，加入方法可行性消融实验，比较 RecA 与普通监督微调、不同数据设置和不同训练顺序的差异，从而说明收益不是由随机训练波动或不可控数据因素造成的。

4.2 基线模型介绍

统一多模态模型的结构差异，主要来自三个问题：理解侧使用什么视觉编码器，生成侧采用什么图像生成范式，以及理解表征和生成路径是否共享同一套参数。为了避免 RecA 只在单一路线中成立，本文选择的基线模型覆盖了几类有代表性的统一多模态建模路线。自回归、掩码生成、掩码自回归和扩散生成等基础范式见附录 A。

第一类是统一参数的理解生成模型。这类模型把视觉理解和视觉生成放在同一个主干网络中，区别主要体现在视觉理解编码器和图像生成方式上。Show-o 使用单一变换器（Transformer）统一理解与生成，并采用类似掩码生成变换器（Masked Generative Image Transformer, MaskGIT）的方式逐步预测图像 token^[2,58]。本文区分 Show-o-VQGAN 和 Show-o-CLIP 两种设置：前者的理解侧使用向量量化生成对抗网络（Vector Quantized Generative Adversarial Network, VQGAN）的离散视觉表示，后者使用对比语言图像预训练（Contrastive Language-Image Pre-

training, CLIP) 视觉表征^[7,59]。这种对比更直接地检验 RecA 是否同时适用于离散视觉编码器和连续语义编码器。Janus-Pro 同样解耦理解和生成所需的视觉编码粒度, 理解侧使用 Sigmoid 损失语言图像预训练 (Sigmoid Loss for Language Image Pre-training, SigLIP) 表征, 生成侧则以下一词元预测 (next-token prediction) 的方式预测图像 token^[60]。Harmon 使用掩码自回归生成 (masked autoregressive generation) 协调理解和生成表示, MMaDA 则把扩散式生成引入多模态语言模型框架^[6,61]。这些模型共同检验 RecA 能否作用于同一主干内部的不同生成范式。

第二类是冻结理解模型并通过查询连接生成模块的路线。MetaQueries 和其开源实现 OpenUni 把预训练多模态理解模型与图像生成模块连接起来, 通过学习查询从冻结的理解模型中提取生成需要的关键信息, 完成理解到生成的传递^[4,62]。这类模型的关键问题是中间表征是否足以驱动高保真生成, 因此非常适合检验 RecA 对理解生成传递链路的影响。

第三类是专家混合变换器 (Mixture-of-Transformers, MoT) 路线, 本文以 BAGEL 为代表。BAGEL 通过大规模统一多模态预训练同时获得理解、生成和编辑能力, 并使用 MoT 结构组织不同模态和任务的计算路径^[5]。将 RecA 应用于 BAGEL, 可以检验重建对齐是否也能迁移到更大规模、更强能力的统一预训练模型中。

这些基线模型的共同点是都试图在同一系统中同时支持视觉理解与视觉生成, 但它们的表征路径和生成方式并不相同。将 RecA 应用于这些模型, 可以检验“使用视觉理解表征对生成路径进行重建对齐”是否只依赖某一种结构实现, 还是能够作为更一般的统一多模态后训练方法。

4.3 跨架构普适性

为了进一步验证 RecA 不是针对某个单一模型调参得到的结果, 本文先在不同架构、不同模型尺寸和不同生成分辨率下比较加入 RecA 前后的文生图表现。表 4.2 延续 GenEval 的子任务拆分方式, 并同时报告 DPGBench 分数^[16-17]。其中括号中的数值表示相对基线的变化。

表 4.1 本文关注的基线模型及其架构特点。

基线模型	架构路线	参数大小
Show-o 系列 ^[2,7,59]	单变换器统一理解与生成；比较 VQGAN 离散表征与 CLIP 连续语义表征；生成侧采用 MaskGIT 式图像词元预测	约 1.3B
Janus-Pro ^[60]	理解侧使用 SigLIP 表征，生成侧通过下一词元预测生成图像词元	7B
Harmon ^[6]	统一参数模型；使用掩码自回归生成协调理解与生成表示	0.5B / 1.5B
MMaDA ^[61]	统一参数模型；多模态扩散语言模型	8B
OpenUni ^[4,62]	MetaQueries 的开源实现；冻结 MLLM，通过可学习查询连接扩散生成模块	1.6B / 3.6B
BAGEL ^[5]	MoT 路线；大规模统一多模态预训练，支持理解、生成和编辑	14B

表 4.2 显示，RecA 在不同架构、不同参数规模 and 不同分辨率设置下都带来了正向提升。提升最明显的是 Harmon 和 OpenUni: Harmon-1.5B 的 GenEval 总分从 72.9 提升到 85.7，DPGBench 从 80.93 提升到 87.21；OpenUni-1.6B 和 OpenUni-3.6B 的双物体、位置和颜色属性子任务提升尤其明显。Janus-Pro 和 MMaDA 的结果进一步说明，RecA 不只适用于 Show-o、OpenUni、Harmon 和 BAGEL 这几类设置，也能迁移到解耦视觉编码和多模态扩散语言模型路线。Show-o-VQGAN-512 的提升相对较小，说明离散图像词元本身更容易引入复制捷径；相比之下，CLIP 表征提供了更强的语义抽象，更符合 RecA 希望利用理解表征校准生成路径的设计目标。

4.4 文生图生成结果

上一节的跨架构实验已经说明，RecA 在多种统一多模态模型上都能带来稳定提升。进一步的问题是：当选择其中表现最强的 1.5B 设置时，RecA 能否把小

表 4.2 RecA 在不同统一多模态模型尺寸和分辨率下的文生图生成结果^[2,4-6,59-61,63]。

模型设置	RecA	GenEval $\uparrow$							DPG $\uparrow$
		单物体	双物体	计数	颜色	位置	颜色属性	总分	分数
Show-o-CLIP-256	×	97.4	63.3	52.1	82.3	14.2	30.3	56.6	70.65
	✓	97.4 (+0.0)	73.6 (+10.3)	56.0 (+3.9)	83.8 (+1.5)	20.3 (+6.1)	40.2 (+9.9)	61.9 (+5.3)	75.70 (+5.05)
Show-o-CLIP-512	×	97.2	80.3	61.9	78.2	27.3	52.3	66.2	82.21
	✓	98.2 (+1.0)	90.6 (+10.3)	66.8 (+4.9)	84.1 (+5.9)	37.4 (+10.1)	56.8 (+4.5)	72.3 (+6.1)	84.94 (+2.73)
Show-o-VQGAN-512	×	98.0	84.0	67.0	82.0	30.0	52.0	68.7	83.63
	✓	98.2 (+0.2)	86.0 (+2.0)	67.2 (+0.2)	83.5 (+1.5)	32.0 (+2.0)	56.8 (+4.8)	70.6 (+1.9)	84.77 (+1.14)
Janus-Pro	×	99.0	88.0	55.4	79.6	75.0	65.1	77.0	84.33
	✓	99.0 (+0.0)	92.0 (+4.0)	55.7 (+0.3)	90.9 (+11.3)	78.6 (+3.6)	72.1 (+7.0)	81.4 (+4.4)	85.85 (+1.52)
OpenUni-1.6B	×	96.8	63.3	46.4	80.1	18.5	30.8	56.0	76.29
	✓	97.1 (+0.3)	84.3 (+21.0)	57.4 (+11.0)	83.5 (+3.4)	44.3 (+25.8)	56.0 (+25.2)	70.4 (+14.4)	80.45 (+4.16)
OpenUni-3.6B	×	99.1	71.8	51.9	83.9	23.3	41.6	61.9	79.02
	✓	99.1 (+0.0)	92.7 (+20.9)	52.3 (+0.4)	87.1 (+3.2)	43.8 (+20.5)	70.3 (+28.7)	74.1 (+12.2)	82.75 (+3.73)
Harmon-0.5B	×	99.7	80.5	55.8	86.7	32.2	49.7	67.6	80.12
	✓	99.9 (+0.2)	92.3 (+11.8)	59.4 (+1.6)	91.7 (+5.0)	58.5 (+26.3)	70.7 (+21.0)	78.7 (+11.1)	84.67 (+4.55)
Harmon-1.5B	×	99.4	87.3	68.7	86.4	44.9	51.1	72.9	80.93
	✓	99.9 (+0.5)	97.7 (+10.4)	71.4 (+2.7)	92.6 (+6.2)	75.7 (+30.8)	76.6 (+25.5)	85.7 (+12.8)	87.21 (+6.28)
MMaDA-DDPM	×	98.4	65.4	47.8	86.2	16.8	28.8	57.2	77.23
	✓	98.8 (+0.4)	72.2 (+6.8)	52.5 (+4.7)	86.4 (+0.2)	21.3 (+4.5)	42.5 (+13.7)	62.3 (+5.1)	79.51 (+2.28)
BAGEL-14B	×	99.1	93.0	79.9	86.0	51.3	63.4	78.8	84.03
	✓	99.3 (+0.2)	93.9 (+0.9)	80.3 (+0.4)	87.6 (+1.6)	60.8 (+9.5)	72.6 (+9.2)	82.4 (+3.6)	85.29 (+1.26)

规模统一模型推进到当前主流文生图模型的水平。为此，本文将 1.5B RecA 模型与已有文生图模型和统一多模态模型进行对比。文生图实验采用 GenEval 和 DPGBench 两个常用评测。GenEval 将文本到图像生成拆分为单物体、双物体、计数、颜色、位置和颜色属性六类子任务，更适合观察模型是否真正遵循组合式指令^[16]。DPGBench 则从更细粒度的图文一致性角度评估生成质量^[17]。表 4.3 按照这两个评测基准的指标结构列出主要结果，所有指标均为越高越好。

在不使用 GPT-4o-Image 蒸馏数据的设置下，1.5B 参数规模的 RecA 模型在 GenEval 总分上达到 0.86，在 DPGBench 上达到 87.21，超过多种更大规模的开源模型。进一步结合 GPT-4o-Image 数据后，RecA 的 GenEval 总分提升到 0.90，DPGBench 提升到 88.15。这个结果说明，RecA 的收益并不只来自更强数据源，

表 4.3 GenEval 和 DPGBench 上的文生图生成结果^[16-17]。带 * 的结果为本地复现实验，↑ 表示越高越好。

模型	参数量	GenEval ↑							DPG ↑
		单物体	双物体	计数	颜色	位置	颜色属性	总分	分数
Harmon*	1.5B	0.99	0.87	0.69	0.86	0.45	0.51	0.73	80.93
SD3-Medium	2B	0.99	0.94	0.72	0.89	0.33	0.60	0.74	84.08
Janus-Pro	7B	0.99	0.89	0.59	0.90	0.79	0.66	0.80	84.33
FLUX-dev	12B	0.99	0.85	0.74	0.79	0.21	0.48	0.68	84.00
BAGEL*	14B	0.99	0.93	0.80	0.86	0.51	0.63	0.79	84.03
Playground-v3	24B	0.99	0.95	0.72	0.82	0.50	0.54	0.76	87.06
GPT-4o-Image	未报告	0.99	0.92	0.85	0.89	0.74	0.71	0.84	86.23
RecA	1.5B	1.00	0.98	0.71	0.93	0.76	0.77	0.86	87.21
使用 GPT-4o-Image 数据训练的模型									
Ovis-U1	3.6B	0.98	0.98	0.90	0.92	0.79	0.75	0.89	83.72
OmniGen2	7B	1.00	0.95	0.64	0.88	0.55	0.76	0.80	83.57
BLIP3-o*	8B	1.00	0.92	0.63	0.91	0.86	0.67	0.83	80.73
RecA	1.5B	1.00	0.97	0.76	0.94	0.91	0.83	0.90	88.15

而是来自重建对齐目标对生成路径的直接校准。

定性结果进一步补充了表 4.3 的数值结论。基线模型往往能够生成大体合理的图像，但在多个物体同时出现、颜色属性绑定或空间关系明确的提示中容易遗漏细节；RecA 通过重建式视觉监督强化了理解表征到生成路径的传递，因此生成结果更容易同时满足主体、属性和布局要求。

4.5 图像编辑结果

前面的实验主要说明 RecA 能提升文生图生成能力。进一步的问题是，对于 BAGEL 这类本身已经具备图像编辑能力的统一多模态模型，RecA 是否仍然有意义。图像编辑比纯文生图更强调对输入图像的保持能力：模型既要执行编辑指令，又不能破坏无关区域、主体身份和整体布局。如果 RecA 只是改善从文本




图 4.1 文生图定性结果对比。左侧为基线模型输出，右侧为加入 RecA 后的输出。结果显示，RecA 后训练后模型在多物体组合、复杂属性和空间布局上更稳定，也更容易保留提示中要求的细粒度视觉关系。



图 4.2 RecA 在不同文生图提示上的可视化结果。相比基线模型，加入 RecA 后的模型更容易保持多个对象、颜色属性和空间关系。

到图像的生成过程，它未必能帮助编辑；但如果 RecA 真正增强了理解表征到生成路径的细粒度传递，那么它也应该改善编辑任务中的身份保持和局部修改。表 4.4 给出了 ImgEdit 和 GEdit-Bench-EN 上的结果^[18-19]。

结果显示，即使基线 BAGEL 已经具备较强编辑能力，加入 RecA 后仍然可以继续提升：在 ImgEdit 上，BAGEL-RecA 的所有子任务均优于 BAGEL，总分从 3.38 提升到 3.75；在 GEdit-Bench-EN 上，总分从 6.94 提升到 7.27。这个结果说明，RecA 的收益并不局限于文本条件生成，也会作用于“在保留输入图像的前提下进行局部修改”。由于 RecA 的训练目标要求模型根据理解表征重建输入图像，它天然强化了对主体结构 and 局部细节的保留能力，因此这种提升不仅体现在新增或替换对象上，也体现在背景、风格、组合编辑等需要保持上下文一致性

表 4.4 图像编辑评测基准上的结果^[18-19]。ImgEdit 报告不同编辑类型及总体分数，GEdit-Bench-EN 报告语义一致性、感知质量和总体分数。

方法	ImgEdit ↑										GEdit-Bench-EN ↑		
	背景	风格	调整	扩展	移除	替换	添加	组合	动作	总分	SC	PQ	总分
Gemini 2.0	未报告	未报告	未报告	未报告	未报告	未报告	未报告	未报告	未报告	未报告	5.43	6.78	5.36
GPT-4o-Image	4.57	4.93	4.33	2.90	3.66	4.35	4.61	3.96	4.89	4.20	7.85	7.62	7.53
BAGEL-NHR	3.56	4.43	3.62	1.57	3.17	3.98	4.12	2.88	3.85	3.48	8.04	6.87	7.08
FLUX-Kontext	3.89	4.62	3.69	1.81	2.97	4.20	3.80	3.00	4.18	3.60	6.95	7.30	6.27
BAGEL	3.38	4.53	3.58	1.49	3.15	3.82	3.71	2.64	4.21	3.38	7.96	6.64	6.94
BAGEL-RecA	3.85	4.73	3.86	1.68	3.75	4.28	4.20	2.94	4.56	3.75	8.24	6.87	7.27
相对 BAGEL 提升	+0.47	+0.20	+0.28	+0.19	+0.60	+0.44	+0.49	+0.30	+0.35	+0.37	+0.28	+0.23	+0.37



图 4.3 图像编辑定性结果对比。每组结果从左到右分别为输入图像、基线模型输出和加入 RecA 后的输出。结果显示，RecA 在雪景转换、服饰添加、对象替换和像素风格迁移等任务中更好地保持了原图主体、空间布局和局部结构，同时更准确地执行编辑指令。

的任务上。

图 4.3 展示了这一点。基线模型在执行编辑时容易破坏输入图像的身份和结构，例如雪景转换中建筑形态发生明显偏移，添加服饰时主体细节波动较大，替换游艇时容易改变海面与主体位置关系。RecA 后训练后的模型能在完成编辑目标的同时保留更多原图信息。这与定量结果中的背景、替换、添加和组合编辑提升一致，也说明重建对齐确实强化了模型对输入视觉条件的利用。

表 4.5 RecA 的可行性消融：后训练目标、数据规模与数据来源。↑ 表示越高越好^[14,35,64-66]。

消融维度	数据设置	训练方式	规模/质量	GenEval ↑	DPG ↑
训练目标	MidjourneyV6	SFT	240k	74.76	80.89
	MidjourneyV6（密集描述）	SFT	240k	74.05	80.67
	MidjourneyV6	RecA	240k	85.69	87.21
	MidjourneyV6	SFT + RecA	240k	81.22	86.54
	BLIP3o-60k	SFT	60k	84.95	85.19
	BLIP3o-60k	RecA	60k	85.21	86.50
	BLIP3o-60k	SFT + RecA	60k	86.14	85.96
	BLIP3o-60k (w/o GenEval)	SFT	60k	80.88	85.24
	BLIP3o-60k (w/o GenEval)	RecA	60k	84.76	86.37
数据规模	MidjourneyV6	RecA	10k	84.6	86.82
	MidjourneyV6	RecA	50k	85.3	87.06
	MidjourneyV6	RecA	240k	85.7	87.21
数据来源	JourneyDB	RecA	中等质量	85.2	86.71
	BLIP3o-60k	RecA	高质量	85.2	86.50
	MidjourneyV6	RecA	高质量	85.7	87.21
	COCO2014	RecA	较低质量	85.3	86.82

4.6 方法可行性消融实验

上述分数说明 RecA 能提升不同模型上的生成与编辑表现，但还需要排除另一种可能：提升是否只是来自额外训练步数、更强数据集或随机训练波动。为此，本文进一步比较普通监督微调（Supervised Fine-Tuning, SFT）与 RecA 在相同后训练数据和相近训练步数下的表现，并补充不同数据来源下的结果。这个实验不追问 RecA 内部哪一类表征最关键，而是先验证方法收益是否具有可重复、可控制的来源。

表 4.5 从三个角度排除不可控因素。第一，额外训练步数不足以解释 RecA 的收益：在 MidjourneyV6 上，普通 SFT 的 GenEval 为 74.76，而替换为 RecA

表 4.6 SFT 与 RecA 的训练顺序消融。

RecA 数据集	训练顺序	GenEval $\uparrow$	DPG $\uparrow$
BLIP3o-60k	RecA $\rightarrow$ SFT	85.91	85.67
BLIP3o-60k	SFT $\rightarrow$ RecA	89.00	87.50
MidjourneyV6	SFT $\rightarrow$ RecA	90.15	88.15

后提升到 85.69；即使给 SFT 使用更密集文本描述，结果也没有变好。换到 BLIP3o-60k 这类不同来源的数据后，RecA 仍然能够超过对应的 SFT 设置；更重要的是，在去掉 GenEval 模板泄漏风险的 BLIP3o-60k 设置中，SFT 的 GenEval 降到 80.88，而 RecA 仍能达到 84.76。第二，随着 MidjourneyV6 数据规模从 10k 增加到 240k，RecA 的 GenEval 和 DPGBench 分数稳定上升，说明方法仍能从更多无标注图像中获益。第三，RecA 在 JourneyDB、BLIP3o-60k、MidjourneyV6 和 COCO2014 上都保持在相近的高分区间，说明它不依赖单一数据分布；高质量合成数据效果更好，但真实图像数据同样能够提供有效的重建监督。训练顺序实验还显示，先用 SFT 建立粗粒度图文对应关系、再用 RecA 进行重建校准后，模型可以进一步达到 GenEval 0.90 和 DPGBench 88.15^[14]。这些结果共同说明，RecA 依赖重建对齐提供的密集视觉监督，而非评测模板、额外图像描述或不可控的数据偶然性。

训练顺序消融进一步说明，RecA 更适合作为后训练末端的校准阶段。先做 SFT 再做 RecA 时，模型先获得基本的文本到图像对应关系，再通过重建对齐补足文本监督缺失的视觉细节；反过来，如果 RecA 之后再回到普通 SFT，密集视觉监督带来的细粒度对齐会被稀疏文本监督部分冲淡。因此，RecA 的作用在于为已有生成路径提供明确的语义重建目标，而非随机扰动模型参数。

4.7 实验小结

上述实验可以得到三个结论。第一，RecA 在 Show-o、Janus-Pro、OpenUni、Harmon、MMaDA 和 BAGEL 等不同架构上均能带来正向收益，覆盖离散图像生

成、扩散生成和掩码自回归生成等多种实现范式，说明它针对的是统一多模态模型中较普遍的理解生成失配，而非某个单一模型的偶然缺陷。第二，在确认跨架构有效后，本文进一步看到 1.5B 规模模型经过 RecA 后在 GenEval 和 DPGBench 上达到或超过若干更大规模模型，并在图像编辑任务上持续提升 BAGEL 这类已有编辑能力的模型，说明重建对齐不仅改善静态生成质量，也能增强条件保持和编辑一致性。第三，可行性消融表明，RecA 的收益与重建对齐目标本身有关，不能由普通 SFT、额外图像描述、数据规模、数据来源或训练顺序随机性充分解释。

不同模型上的提升幅度并不完全相同，这也为后续分析提供了线索：如果某个模型的理解表征已经较容易被生成路径利用，RecA 的边际收益可能较小；如果模型的理解侧和生成侧存在明显表征断裂，RecA 的提升就会更显著。第四章到此只回答“方法是否有效、是否可控”，第五章将进一步转向机制问题，分析收益来自哪一类表征、哪一部分训练模块以及哪一种监督信号。

5 RecA 的机制消融实验

5.1 分析目标与实验设置

第四章已经证明 RecA 在多种统一多模态模型上均能带来稳定收益。本章进一步回答一个更细的问题：RecA 的收益来自哪里。若它只是增加了训练数据、固定了某个提示词模板，或者偶然改善了某一类样本，那么其机制解释并不充分；若它主要通过重建目标把理解侧表征重新接入生成路径，则收益应当对提示词不敏感，并且会集中出现在能同时表达语义与空间关系的中后层表征上。

因此，本章以 MetaQueries (OpenUni) 作为主要分析对象^[4]。选择 OpenUni 的原因在于，它足够轻量、生成效果较好，并且可以冻结理解层，只训练从理解表征到生成模块之间的连接部分。这种结构使得消融实验更干净：当理解层被冻结时，性能变化更容易归因于 RecA 如何利用已有理解表征，避免被整个多模态模型共同漂移干扰。具体来说，OpenUni 使用冻结的多模态大语言模型作为理解侧表征来源，并通过可学习查询连接生成模块；本文在该框架下分析四类问题：（1）极少量图像是否足以产生收益；（2）提示词模板是否是收益来源；（3）使用多少层理解表征进行重建，才能真正带来生成性能提升；（4）当理解侧和生成侧来自同一模型族但并非原生统一模型时，RecA 是否仍能把视觉条件转化为生成能力。

图 5.1 给出了 MetaQueries 的基本流程。理解侧使用冻结的 InternVL/MLLM 提取多模态表征，生成侧使用可学习查询作为条件入口，并通过连接器把理解表征传递给扩散生成模块。实现上，MetaQueries 不会在所有理解层中无限制地读取图像信息，而是让可学习查询只在前 k 层与图像表征交互；随后这些查询作为生成条件进入后续扩散模块。在本文采用的 OpenUni 设置中，InternVL 理解侧共有 28 层，因此后续“前 7 层、前 14 层、前 21 层、完整 28 层”的消融，实际对应的是：使用多少层理解表征参与 RecA 重建监督。

需要说明的是，本章图中使用的 GenEval 平均值，是去掉单对象任务后得到的五项平均分，即双对象、计数、颜色、位置和颜色属性五项平均。这样处理不




图 5.1 MetaQueries (OpenUni) 的理解到生成连接流程。冻结的 MLLM 保留理解能力；可学习查询只在前 k 层与图像表征交互，并经连接器形成扩散生成条件。本文利用这一结构分析不同层数理解表征对 RecA 重建对齐的贡献。

会改变评价标准，同时能让机制消融更敏感。在本组实验中，单对象任务基本接近满分，不同设置之间差异很小；如果把它计入平均值，会稀释层级选择、提示词模板和重建监督对复杂生成能力的影响。相比之下，双对象、计数、位置和颜色属性更依赖对象关系、属性绑定和空间结构，更适合分析 RecA 具体改善了哪些生成能力。

5.2 数据规模与提示词模板消融

第一组消融用于排除两个简单解释：RecA 是否只是在小样本上“记住”图像，或者是否依赖某个特定的文本提示词。为此，本文分别改变训练图像数量和重建提示词模板。提示词模板消融中，完整设置使用 360 条多样化描述；单提示词设置只保留一条正向模板“keep the image as it is”；负向提示词设置则使用“destroy the image”作为极端对照。后两者故意压缩或破坏文本侧语义，用来观察 RecA 是否仍能依靠图像重建目标获得收益。

表 5.1 OpenUni 上数据规模与提示词模板消融。分数为去掉单对象后的 GenEval 五项平均分。基线使用第四章中 OpenUni-3.6B 未加入 RecA 的结果。

消融维度	设置	五项平均分	相对基线	相对完整设置
基线模型	不使用 RecA	54.50	不适用	-14.58
图像数量	64 张图像（最佳）	56.52	+2.02	-12.56
提示词模板	360 条多样化提示词	69.08	+14.58	不适用
提示词模板	1 条正向提示词（keep the image as it is）	67.46	+12.96	-1.62
提示词模板	1 条负向提示词（destroy the image）	67.38	+12.88	-1.70

表 5.1 给出了主要结果。未加入 RecA 的 OpenUni-3.6B 基线五项平均分为 54.50。仅使用 64 张图像时，最佳结果为 56.52，只比基线高 2.02 分；继续训练到 5000 训练步时分数下降到 55.11，说明少量图像更容易让模型过拟合重建任务本身，而不是学到可以稳定迁移到 GenEval 的理解生成对齐关系。当图像数量足够后，即使只保留一条正向提示词，模型仍然能达到 67.46；即使把提示词换成负向语义，分数仍为 67.38。相比 360 条提示词的完整设置，两种极简提示词分别下降 1.62 和 1.70，但没有使收益消失。

这说明 RecA 的主要监督并不来自提示词模板本身。提示词的作用更像是提供一个可被模型读取的条件入口，而不是决定训练目标的核心语义。真正关键的是图像重建带来的密集视觉监督：图像数量太少时，监督覆盖不到足够多的对象、属性和空间状态，因此难以稳定转化为生成能力；提示词变少甚至变成负向描述时，只要图像重建目标仍然存在，模型仍能学习到理解表征到生成路径的对齐关系。

5.3 重建层数范围消融

第二组消融关注一个更直接的机制问题：RecA 需要使用多少层理解表征进行重建。这里的“层数”指用于重建监督的理解层输出范围，而不是模型推理时

的缓存实现。本文比较四种设置：使用完整 28 层表征、仅使用前 21 层、仅使用前 14 层和仅使用前 7 层。结果如图 5.2 所示，完整 28 层在 3000 训练步达到五项平均分 69.48，5000 训练步仍保持 69.31；仅前 21 层和仅前 14 层可以达到 67 左右；仅前 7 层最高只有 61.36，且位置与颜色属性两项明显偏低。




图 5.2 OpenUni 上重建层数范围消融。图中给出不同层数范围随训练步数变化的 GenEval 五项平均分。仅使用前 7 层显著落后，说明低层视觉信息不足以支撑 RecA 的主要收益。




图 5.3 OpenUni 上不同重建层数范围在 5000 训练步时的 GenEval 子任务分数。差距主要出现在双物体、位置和颜色属性等更依赖关系建模的任务上。

这一结果支持一个明确判断：RecA 不是单纯学习低层纹理重建。前 7 层能够提供颜色、边缘和局部纹理，因此颜色任务仍保留一定性能，但双对象、位置和颜色属性明显不足。这些任务需要对象级语义、属性绑定和空间关系，通常更依赖中后层表征。前 14 层和前 21 层已经恢复大部分收益，说明一旦引入足够的中层语义，RecA 就可以把理解侧信息转化为生成端可用的条件。

从子任务看，完整 28 层在 5000 训练步的双对象、位置和颜色属性分别达到 91.16、41.50 和 68.25；仅前 7 层对应为 81.57、27.00 和 50.00。差距主要出现在关系和属性绑定层面，简单颜色识别并不是主要瓶颈。这与 RecA 的目标一致：它改善的是理解表征在生成路径中的利用效率，而不只是让生成器见到某种颜色。

5.4 单层特征重建消融

第三组消融进一步把范围消融拆到单层。实验分别取第 14 层到第 27 层的单层表征进行重建对齐，并记录不同训练步数下的 GenEval 变化。图 5.4 显示，第 20 层在不同训练步数下表现最一致，5000 训练步达到 69.05；第 16 层在 3000

训练步达到 68.79；第 21 层在 5000 训练步达到 68.17。相反，第 14、17、18、19、25 层整体较弱。

重建层数	训练步数				
	1k	2k	3k	4k	5k
L14	63.4	63.9	63.9	63.7	63.9
L15	–	65.2	64.7	66.2	65.7
L16	64.9	67.1	68.8	68.6	68.5
L17	63.9	63.6	63.6	64.0	63.8
L18	63.6	63.4	63.9	64.1	63.5
L19	63.0	63.1	62.8	63.3	63.2
L20	65.8	68.2	68.9	68.8	69.1
L21	65.4	66.3	67.0	68.0	68.2
L22	63.7	65.0	65.6	65.1	65.3
L23	64.6	65.7	66.6	66.6	66.4
L24	64.7	65.8	65.9	65.7	66.7
L25	63.2	62.8	63.6	63.4	63.7
L26	64.4	65.6	65.9	65.8	65.9
L27	63.8	64.7	65.3	65.3	65.0

图 5.4 单层特征重建消融的 GenEval 平均分热力图。数值为双对象、计数、颜色、位置和颜色属性五项平均。中后层，尤其第 20 层，在不同训练步数下表现更一致；较浅层和过深层都不能保证更高收益。

这个现象比“层越深越好”更具体。第 20 层在五项平均分、双对象、计数和颜色属性上都接近或达到最优，其中五项平均分最优为 69.05，双对象最优为 84.85，计数最优为 63.44，颜色属性最优为 52.75。第 16 层在位置任务上达到 30.50，是单层设置中最好的空间关系结果。第 24 层在颜色任务上达到 87.23，但其整体平均不如第 20 层。

因此，RecA 的有效层区间更接近“中后层语义瓶颈”，而不是最低层视觉细节或最高层文本指令。较浅层缺少足够的对象关系抽象；过深层可能更贴近语言决策和任务输出，反而不一定保留生成端需要的细粒度视觉状态。第 20 层的稳定性说明，RecA 最需要的是同时包含视觉细节、对象关系和语义绑定的中间

表征。

5.5 重建损失与生成指标的关系

最后一组分析比较图像到图像重建损失与 GenEval 的关系。图 5.5 给出第 14 层到第 27 层的重建损失曲线。所有层的损失随训练下降，但下降幅度和最终位置并不相同。第 20 层最终损失最低，为 0.8389；第 21 层为 0.8446；第 16 层为 0.8523。与前文 GenEval 结果对应，第 20 层同时拥有最低重建损失和最高单层平均分。




图 5.5 左：不同层的图像到图像重建损失曲线。右：最终重建损失与最佳 GenEval 平均分的关系。

从整体相关性看，最终重建损失与最佳 GenEval 五项平均分之间的 Pearson 相关系数为 $r = -0.93$ ；若将指标写成负重建损失，即“重建损失越低越好”，则相关系数为 $r = 0.93$ 。这说明重建目标和生成评价之间存在很强的一致性：更容易被重建目标优化的层，通常也更能提升生成中的对象关系、属性绑定和空间控制。

不过，重建损失不能完全解释所有生成指标。第 16 层的最终损失高于第 21 层，但其 GenEval 最优平均分达到 68.79，尤其位置子任务更强。这说明 RecA 需要找到适合生成任务的表征层，而不能只追求更低的重建损失：该层既要能被重建目标稳定优化，又要包含生成评价所需要的对象、属性和关系信息。重建损失提供了训练是否有效的信号，但最终生成能力仍由表征内容决定。

5.6 非统一多模态模型上的重建对齐

前面的实验主要讨论 OpenUni 这类本来就带有理解生成连接结构的统一多模态模型。本节换一个不同设置：使用 Z-Image 作为生成模型。Z-Image 的主体是基于 Qwen3 的文生图模型，而不是 Qwen3-VL；它原本更像一个只接收文本条件的生成模型，并没有天然的图像理解输入。因此，本节关注的问题是：如果直接给这种非统一多模态模型接入 ViT 视觉信息，重建对齐还能不能把这部分信息变成生成模型可以用的条件。

实验结果比预期更直接。本文没有把 Z-Image 重新改造成完整的视觉语言模型，也没有让它先学习复杂的图文问答任务，而是将视觉表征接入生成条件侧，再用 RecA 的图像重建目标进行对齐。按直觉看，这种做法并不容易成立：Qwen3 本身负责语言建模，ViT 负责视觉编码，二者并不来自同一个统一多模态训练框架。但如图 5.6 所示，只要通过重建目标把视觉信息压进生成条件空间，Z-Image 就开始能够利用这些视觉信息。

具体来看，图 5.6 左列是输入图像，中间列是 Qwen3+ViT 零样本生成的原始 caption，右列是加入视觉信息并进行 RecA 重建后的结果。可以看到，这些原始 caption 已经包含白马、雪地、手袋、哈士奇、旗袍等关键视觉元素。经过 RecA 重建后，这些主体和风格又被重新带回生成结果中。这里真正值得注意的是，Z-Image 原本不是一个图像输入模型，但直接接入 ViT 后仍然可以被重建目标拉起来。这说明 RecA 的作用门槛比想象中低：它不一定要模型一开始就是完整的统一多模态结构。




图 5.6 非统一多模态模型上的 RecA 重建结果。中间列为 Qwen3+ViT 零样本生成的原始 caption，右列为 RecA 重建结果。

这种现象不只体现在定性图上。表 5.2 给出了 Z-Image 在 GenEval 上的主要结果。可以看到，RecA 后平均分从 69.92 提升到 77.27，其中计数从 61.88 提升到 75.94，位置从 31.25 提升到 41.75，颜色属性从 58.00 提升到 65.25。这些提升主要集中在对象数量、空间关系和属性绑定上，而不是只改善单物体这种相对简单的任务。

表 5.2 非统一多模态模型上的重建对齐结果。分数为 GenEval 各子任务准确率，↑表示越高越好。

方法	单物体	双物体	计数	颜色	位置	颜色属性	平均
Z-Image 基线	98.75	86.11	61.88	83.51	31.25	58.00	69.92
RecA 500 步	99.38	91.67	75.94	89.63	41.75	65.25	77.27

这组实验值得注意的地方在于，RecA 的作用并不局限在“模型已经统一，只差一点对齐”的场景里。即使生成模型本体只是 Qwen3 系列的文生图模型，只要外部 ViT 能提供可用的视觉表征，重建目标仍然可以把这部分表征变成生成模型能利用的条件。由此可见，RecA 不只是修补统一多模态模型内部的接口，它也提供了一种更简单的思路：先把视觉信息接进来，再用重建任务迫使生成模型学会使用这部分信息。

5.7 机制小结

本章的消融结果可以归纳为四点。第一，提示词模板对 **RecA** 收益的贡献有限；即使只保留一条提示词，甚至使用负向提示词，模型仍能受益，但图像数量过少时收益波动较大，说明密集视觉监督是核心。第二，**RecA** 依赖中后层理解表征。仅前 7 层明显不足，而前 14 层、前 21 层和完整 28 层都能恢复较大部分收益。第三，单层实验表明最有效的层集中在第 16、20、21 和 24 层，其中第 20 层在不同训练步数下表现更一致，兼具低重建损失和高 **GenEval** 表现。第四，**Z-Image** 实验说明，在非统一多模态模型中，直接接入 ViT 视觉信息也可以通过 **RecA** 被生成模型利用，这使得重建对齐的适用范围比原本预期更宽。

这些结果共同支持本文的机制解释：**RecA** 通过图像重建把理解侧的中高层视觉语义重新对齐到生成路径中，其作用不能归结为记住训练图像或通过文本提示词调整采样偏好。当这一对齐发生在合适层级时，模型在对象关系、属性绑定和空间位置等任务上获得更稳定的提升。

6 总结与展望

6.1 工作总结

本文围绕统一多模态模型中的 **RecA** 方法展开研究。现有统一模型虽然能够在同一框架中同时处理理解和生成任务，但理解路径得到的表征并不一定能被生成路径充分利用。针对这一问题，本文从方法介绍、基线模型与跨模型实验、可行性分析和机制消融三个部分展开。

首先，本文分析了统一多模态模型在视觉理解与生成统一建模过程中面临的核心矛盾，指出文本监督信号稀疏和内部表征利用不足是限制生成质量的重要原因。随后，本文介绍了 **RecA** 的基本思想：利用模型自身的视觉理解表征作为密集条件信号，并通过重建训练增强生成路径对结构化视觉信息的利用。

在实验层面，本文先梳理 **Show-o**、**Janus-Pro**、**MetaQueries/OpenUni**、**Harmon**、**MMaDA** 和 **BAGEL** 等基线架构，再围绕 **RecA** 的普适性设计跨模型评估，比较加入 **RecA** 前后的生成与编辑表现。随后，本文通过 **SFT** 对比、数据设置和训练顺序等可行性消融排除随机训练因素，并在 **OpenUni** 上进一步进行层级表征、训练模块和监督信号等机制消融分析。此外，本文还在 **Z-Image** 上补充了非统一多模态模型的重建对齐实验，说明直接接入外部视觉表征也可能被生成模型利用。

6.2 不足与展望

本文当前工作仍存在一些不足。首先，重建对齐机制的有效性还需要在更多模型结构和数据规模上验证。不同统一模型的内部表征形式不同，后训练策略可能需要针对具体架构进行调整。其次，**Z-Image** 上的实验说明外部视觉表征可以被重建目标利用，但目前仍只是初步验证，还需要更系统地比较不同视觉编码器和连接方式。最后，如何平衡重建保真度与开放式生成能力，仍然需要进一步实验分析。

未来可以从三个方向继续推进。第一，补充更多跨模型实验结果，进一步确

认 RecA 的普适性。第二，设计更细粒度的 OpenUni 消融实验，明确不同隐藏层和训练模块在理解生成对齐中的功能分工。第三，在非统一多模态模型上比较不同视觉编码器、连接器和训练步数设置，进一步确认重建对齐在更弱结构假设下的适用边界。

参考文献

- [1] ZHAO S, ZHANG X, GUO J, et al. Unified Multimodal Understanding and Generation Models: Advances, Challenges, and Opportunities[J/OL]. arXiv preprint arXiv:2505.02567, 2025. <https://arxiv.org/abs/2505.02567>. DOI: 10.48550/arXiv.2505.02567.
- [2] XIE J, MAO W, BAI Z, et al. Show-o: One Single Transformer to Unify Multimodal Understanding and Generation[J/OL]. arXiv preprint arXiv:2408.12528, 2024. <https://arxiv.org/abs/2408.12528>. DOI: 10.48550/arXiv.2408.12528.
- [3] WU C, CHEN X, WU Z, et al. Janus: Decoupling Visual Encoding for Unified Multimodal Understanding and Generation[J/OL]. arXiv preprint arXiv:2410.13848, 2024. <https://arxiv.org/abs/2410.13848>. DOI: 10.48550/arXiv.2410.13848.
- [4] WU S, WU Z, GONG Z, et al. OpenUni: A Simple Baseline for Unified Multimodal Understanding and Generation[J/OL]. arXiv preprint arXiv:2505.23661, 2025. <https://arxiv.org/abs/2505.23661>. DOI: 10.48550/arXiv.2505.23661.
- [5] DENG C, et al. BAGEL: ByteDance Open-Source Unified Model for Multimodal Understanding and Generation[J/OL]. arXiv preprint arXiv:2505.14683, 2025. <https://arxiv.org/abs/2505.14683>. DOI: 10.48550/arXiv.2505.14683.
- [6] WU S, WANG X, WU Y, et al. Harmonizing Visual Representations for Unified Multimodal Understanding and Generation[J/OL]. arXiv preprint arXiv:2503.21979, 2025. <https://arxiv.org/abs/2503.21979>. DOI: 10.48550/arXiv.2503.21979.
- [7] RADFORD A, KIM J W, HALLACY C, et al. Learning Transferable Visual Models From Natural Language Supervision[J/OL]. arXiv preprint arXiv:2103.00020, 2021. <https://arxiv.org/abs/2103.00020>. DOI: 10.48550/arXiv.2103.00020.
- [8] XIE J, YANG Z, SHOU M Z. Show-o2: Improved Native Unified Multimodal Models[J/OL]. arXiv preprint arXiv:2506.15564, 2025. <https://arxiv.org/abs/2506.15564>. DOI: 10.48550/arXiv.2506.15564.
- [9] MA Y, LIU X, CHEN X, et al. JanusFlow: Harmonizing Autoregression and Rectified Flow for Unified Multimodal Understanding and Generation[J/OL]. arXiv preprint arXiv:2411.07975, 2024. <https://arxiv.org/abs/2411.07975>. DOI: 10.48550/arXiv.2411.07975.
- [10] WEI C, LIU Q, YE Z, et al. UniVideo: Unified Understanding, Generation, and Editing for Videos[J/OL]. arXiv preprint arXiv:2510.08377, 2025. <https://arxiv.org/abs/2510.08377>. DOI: 10.48550/arXiv.2510.08377.
- [11] XU P, TANG P, LUO D, et al. Towards Generalized Multi-Image Editing for Unified Multimodal Models[J/OL]. arXiv preprint arXiv:2601.05572, 2026. <https://arxiv.org/abs/2601.05572>. DOI: 10.48550/arXiv.2601.05572.
- [12] WEI H, WEN B, LONG Y, et al. UniRef-Image-Edit: Towards Scalable and Consistent Multi-Reference Image Editing[J/OL]. arXiv preprint arXiv:2602.14186, 2026. <https://arxiv.org/abs/2602.14186>. DOI: 10.48550/arXiv.2602.14186.
- [13] HAN R, FANG Z, SUN X, et al. UniCorn: Towards Self-Improving Unified Multimodal Models through Self-Generated Supervision[J/OL]. arXiv preprint arXiv:2601.03193, 2026. <https://arxiv.org/abs/2601.03193>. DOI: 10.48550/arXiv.2601.03193.
- [14] XIE J, DARRELL T, ZETTLEMOYER L, et al. Reconstruction Alignment Improves Unified Multimodal Models[J/OL]. arXiv preprint arXiv:2509.07295, 2025. <https://arxiv.org/abs/2509.07295>. DOI: 10.48550/arXiv.2509.07295.
- [15] PAN J, LI L, PENG Y, et al. Learning to Generate via Understanding: Understanding-Driven Intrinsic Rewarding for Unified Multimodal Models[J/OL]. arXiv preprint arXiv:2603.06043, 2026. <https://arxiv.org/abs/2603.06043>. DOI: 10.48550/arXiv.2603.06043.

- [16] GHOSH D, HAJISHIRZI H, SCHMIDT L. GenEval: An Object-Focused Framework for Evaluating Text-to-Image Alignment[J/OL]. arXiv preprint arXiv:2310.11513, 2023. <https://arxiv.org/abs/2310.11513>. DOI: 10.48550/arXiv.2310.11513.
- [17] HU X, CHENG P, et al. ELLA: Equip Diffusion Models with LLM for Enhanced Semantic Alignment[J/OL]. arXiv preprint arXiv:2403.05135, 2024. <https://arxiv.org/abs/2403.05135>. DOI: 10.48550/arXiv.2403.05135.
- [18] YE Y, HE X, LI Z, et al. Imgedit: A unified image editing dataset and benchmark[J]. arXiv preprint arXiv:2505.20275, 2025.
- [19] LIU S, HAN Y, XING P, et al. Step1x-edit: A practical framework for general image editing [J]. arXiv preprint arXiv:2504.17761, 2025.
- [20] LI Z, XIE C, VAN DURME B, et al. Localization vs. Semantics: Visual Representations in Unimodal and Multimodal Models[C]//Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (EACL). 2024: 2378-2390.
- [21] CHEN M, RADFORD A, CHILD R, et al. Generative Pretraining from Pixels[C/OL]//Proceedings of the 37th International Conference on Machine Learning (ICML). 2020. <http://proceedings.mlr.press/v119/chen20s.html>.
- [22] RAMESH A, PAVLOV M, GOH G, et al. Zero-Shot Text-to-Image Generation[J/OL]. arXiv preprint arXiv:2102.12092, 2021. <https://arxiv.org/abs/2102.12092>. DOI: 10.48550/arXiv.2102.12092.
- [23] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-Resolution Image Synthesis with Latent Diffusion Models[J/OL]. arXiv preprint arXiv:2112.10752, 2021. <https://arxiv.org/abs/2112.10752>. DOI: 10.48550/arXiv.2112.10752.
- [24] CompVis. Stable Diffusion Model Card / Repository (v1 series)[EB/OL]. 2022. <https://huggingface.co/CompVis/stable-diffusion-v1-3>.
- [25] SAHARIA C, CHAN W, SAXENA S, et al. Photorealistic Text-to-Image Diffusion Models with Deep Language Understanding[J/OL]. arXiv preprint arXiv:2205.11487, 2022. <https://arxiv.org/abs/2205.11487>. DOI: 10.48550/arXiv.2205.11487.
- [26] LIPMAN Y, CHEN R T Q, BEN-HAMU H, et al. Flow Matching for Generative Modeling [J/OL]. arXiv preprint arXiv:2210.02747, 2022. <https://arxiv.org/abs/2210.02747>. DOI: 10.48550/arXiv.2210.02747.
- [27] LIU X, GONG C, LIU Q. Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow[J/OL]. arXiv preprint arXiv:2209.03003, 2022. <https://arxiv.org/abs/2209.03003>. DOI: 10.48550/arXiv.2209.03003.
- [28] Black Forest Labs, BATIFOL S, BLATTMANN A, et al. FLUX.1 Kontext: Flow Matching for In-Context Image Generation and Editing in Latent Space[J/OL]. arXiv preprint arXiv:2506.15742, 2025. <https://arxiv.org/abs/2506.15742>. DOI: 10.48550/arXiv.2506.15742.
- [29] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.
- [30] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[J/OL]. arXiv preprint arXiv:2203.02155, 2022. <https://arxiv.org/abs/2203.02155>. DOI: 10.48550/arXiv.2203.02155.
- [31] LEE H, KAPOOR A, et al. RLAI vs. RLHF: Scaling Reinforcement Learning from Human Feedback with AI Feedback[J/OL]. arXiv preprint arXiv:2309.00267, 2023. <https://arxiv.org/abs/2309.00267>. DOI: 10.48550/arXiv.2309.00267.
- [32] RAFAILOV R, SHARMA A, MITCHELL E, et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model[J/OL]. arXiv preprint arXiv:2305.18290, 2023. <https://arxiv.org/abs/2305.18290>. DOI: 10.48550/arXiv.2305.18290.
- [33] RAFAILOV R, SHARMA A, MITCHELL E, et al. Direct preference optimization: Your language model is secretly a reward model[J]. Advances in neural information processing

- systems, 2023, 36: 53728-53741.
- [34] SHAO Z, WANG P, ZHU Q, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models[J]. arXiv preprint arXiv:2402.03300, 2024.
 - [35] CHEN J, XU Z, PAN X, et al. Blip3-o: A family of fully open unified multimodal models-architecture, training and dataset[J]. arXiv preprint arXiv:2505.09568, 2025.
 - [36] OpenAI. Introducing GPT-4o with image generation capabilities[EB/OL]. 2024. <https://openai.com/index/introducing-4o-image-generation>.
 - [37] XIE Q, LUONG M T, HOVY E, et al. Self-training with Noisy Student improves ImageNet classification[J/OL]. arXiv preprint arXiv:1911.04252, 2019. <https://arxiv.org/abs/1911.04252>. DOI: 10.48550/arXiv.1911.04252.
 - [38] WANG Y, KORDI Y, MISHRA S, et al. Self-Instruct: Aligning Language Models with Self-Generated Instructions[J/OL]. arXiv preprint arXiv:2212.10560, 2022. <https://arxiv.org/abs/2212.10560>. DOI: 10.48550/arXiv.2212.10560.
 - [39] MADAAN A, TANDON N, GUPTA P, et al. Self-Refine: Iterative Refinement with Self-Feedback[J/OL]. arXiv preprint arXiv:2303.17651, 2023. <https://arxiv.org/abs/2303.17651>. DOI: 10.48550/arXiv.2303.17651.
 - [40] MAO W, YANG Z, SHOU M Z. UniRL: Self-Improving Unified Multimodal Models via Supervised and Reinforcement Learning[J/OL]. arXiv preprint arXiv:2505.23380, 2025. <https://arxiv.org/abs/2505.23380>. DOI: 10.48550/arXiv.2505.23380.
 - [41] BAO H, DONG L, PIAO S, et al. BEiT: BERT Pre-Training of Image Transformers[J/OL]. arXiv preprint arXiv:2106.08254, 2021. <https://arxiv.org/abs/2106.08254>. DOI: 10.48550/arXiv.2106.08254.
 - [42] HE K, CHEN X, XIE S, et al. Masked Autoencoders Are Scalable Vision Learners[J/OL]. arXiv preprint arXiv:2111.06377, 2021. <https://arxiv.org/abs/2111.06377>. DOI: 10.48550/arXiv.2111.06377.
 - [43] WANG X, ZHOU X, FATHI A, et al. Visual lexicon: Rich image features in language space[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 19736-19747.
 - [44] WANG H, ZHENG A, ZHAO Y, et al. Reconstructive visual instruction tuning[J]. arXiv preprint arXiv:2410.09575, 2024.
 - [45] WANG H, ZHAO Y, WANG T, et al. Ross3d: Reconstructive visual instruction tuning with 3d-awareness[J]. arXiv preprint arXiv:2504.01901, 2025.
 - [46] YU S, KWAK S, JANG H, et al. Representation alignment for generation: Training diffusion transformers is easier than you think[J]. arXiv preprint arXiv:2410.06940, 2024.
 - [47] YAO J, YANG B, WANG X. Reconstruction vs. generation: Taming optimization dilemma in latent diffusion models[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 15703-15712.
 - [48] PEEBLES W, XIE S. Scalable Diffusion Models with Transformers[J]. arXiv preprint arXiv:2212.09748, 2022.
 - [49] KINGMA D P, WELING M. Auto-encoding variational bayes[J]. arXiv preprint arXiv:1312.6114, 2013.
 - [50] CARON M, TOUVRON H, MISRA I, et al. Emerging properties in self-supervised vision transformers[J]. Proceedings of the IEEE/CVF international conference on computer vision, 2021: 9650-9660.
 - [51] MA S, ZHENG K, WEI Y, et al. Learning visual generative priors without text[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 8051-8061.
 - [52] SHI X, LI B, HAN X, et al. ConsistCompose: Unified Multimodal Layout Control for Image Composition[J/OL]. arXiv preprint arXiv:2511.18333, 2025. <https://arxiv.org/abs/2511.18333>. DOI: 10.48550/arXiv.2511.18333.
 - [53] LI Y, DU Y, ZHOU K, et al. Evaluating Object Hallucination in Large Vision-Language Models[C]//EMNLP. Association for Computational Linguistics, 2023: 292-305.

- [54] FU C, CHEN P, SHEN Y, et al. MME: A Comprehensive Evaluation Benchmark for Multimodal Large Language Models[J/OL]. arXiv preprint arXiv:2306.13394, 2023. <https://arxiv.org/abs/2306.13394>. DOI: 10.48550/arXiv.2306.13394.
- [55] HUDSON D A, MANNING C D. GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering[J/OL]. arXiv preprint arXiv:1902.09506, 2019. <https://arxiv.org/abs/1902.09506>. DOI: 10.48550/arXiv.1902.09506.
- [56] YUE X, NI Y, ZHENG T, et al. MMMU: A Massive Multi-Discipline Multimodal Understanding and Reasoning Benchmark for Expert AGI[C]//CVPR. IEEE, 2024: 9556-9567.
- [57] LI B, WANG R, WANG G, et al. SEED-Bench: Benchmarking Multimodal LLMs with Generative Comprehension[J/OL]. arXiv preprint arXiv:2307.16125, 2023. <https://arxiv.org/abs/2307.16125>. DOI: 10.48550/arXiv.2307.16125.
- [58] CHANG H, ZHANG H, JIANG L, et al. Maskgit: Masked generative image transformer[C]//CVPR. 2022: 11315-11325.
- [59] ESSER P, ROMBACH R, OMMER B. Taming transformers for high-resolution image synthesis[C]//CVPR. 2021: 12873-12883.
- [60] CHEN X, WU Z, LIU X, et al. Janus-Pro: Unified Multimodal Understanding and Generation with Data and Model Scaling[J]. arXiv preprint arXiv:2501.17811, 2025.
- [61] YANG L, TIAN Y, LI B, et al. MMaDA: Multimodal Large Diffusion Language Models[J]. arXiv preprint arXiv:2505.15809, 2025.
- [62] PAN X, SHUKLA S N, SINGH A, et al. Transfer between Modalities with MetaQueries[J]. arXiv preprint arXiv:2504.06256, 2025.
- [63] VAN DEN OORD A, VINYALS O, et al. Neural discrete representation learning[J]. NeurIPS, 2017, 30.
- [64] SUN K, PAN J, GE Y, et al. JourneyDB: A Benchmark for Generative Image Understanding [C]//NeurIPS. 2023.
- [65] CortexLM. CortexLM/midjourney-v6[EB/OL]. 2024. <https://huggingface.co/datasets/CortexLM/midjourney-v6>.
- [66] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft COCO: Common Objects in Context [C]//European Conference on Computer Vision. Springer, 2014: 740-755.
- [67] TEAM C. Chameleon: Mixed-modal early-fusion foundation models[J]. arXiv preprint arXiv:2405.09818, 2024.
- [68] LI T, TIAN Y, LI H, et al. Autoregressive image generation without vector quantization[J]. Advances in Neural Information Processing Systems, 2024, 37: 56424-56445.
- [69] HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models[J]. NeurIPS, 2020: 6840-6851.

附录

A 图像生成范式基础

为保持论述连贯性，原本适合放在附录的完整跨尺寸实验结果和 Show-o 的 VQ-VAE / VQGAN 图像分词器实验，已经并入第 4 章正文。本附录不再重复列出同一组结果，而是结合第 4 章实验中涉及的图像生成范式，整理后文会反复用到的基础概念。统一多模态模型中的图像生成路径并不只有一种实现。本文第 4 章比较的模型大体涉及四类范式：自回归生成、掩码生成、掩码自回归生成，以及扩散或流匹配生成。它们的共同目标都是根据文本或视觉条件产生图像，但建模对象、生成顺序和训练损失不同。

A.1 自回归生成范式

自回归生成 (Autoregressive Generation, AR) 通常先使用图像分词器把图像转换为离散视觉词元序列，然后像语言模型一样逐个预测下一个词元。若图像词元序列记为 $x = (x_1, x_2, \dots, x_N)$ ，则联合概率可以分解为

$$p_\theta(x) = \prod_{i=1}^N p_\theta(x_i | x_{<i}). \quad (\text{A-1})$$

对应的训练目标通常是交叉熵损失：

$$\mathcal{L}_{\text{AR}} = - \sum_{i=1}^N \log p_\theta(x_i | x_{<i}). \quad (\text{A-2})$$

这一路线的优点是形式统一：文本词元和图像词元可以放入同一个序列中，模型只需要学习“预测下一个词元”这一类目标。因此，Chameleon、Janus-Pro 等模型都可以被理解为这一范式的代表^[60,67]。它的不足也很直接：图像词元序列通常远长于文本序列，生成速度会受到限制；同时，早期词元的错误会影响后续预测，导致误差积累。对于 RecA 来说，AR 范式的关键问题是：理解侧表征是否能被转化为足够准确的条件，使生成路径在逐词元预测时仍然保持对象、属性和空间关系。

A.2 掩码生成与离散扩散范式

掩码生成 (Masked Generation) 不要求模型严格按照从左到右的顺序生成图像，而是随机遮盖一部分词元，再让模型预测被遮盖的位置。以 MaskGIT 为代表的方法会从大量被遮盖的词元开始，经过多轮预测和重新掩码，逐步得到完整图像^[58]。如果用 m 表示掩码集合， $x_{\bar{m}}$ 表示未被遮盖的词元，则可以把训练目标写成

$$\mathcal{L}_{\text{mask}} = -\mathbb{E}_m \sum_{i \in m} \log p_{\theta}(x_i | x_{\bar{m}}). \quad (\text{A-3})$$

Show-o 的图像生成侧与这一思想密切相关：它不同于传统的从左到右完整图像序列预测，而是在统一变换器中采用离散扩散或掩码式词元预测机制来生成图像^[2]。这也是第 4 章把 Show-o-VQGAN 和 Show-o-CLIP 放在一起比较的原因。该对比用于观察 RecA 在离散视觉表示和连续语义表示两类理解输入下是否都能工作，而不以证明某个图像分词器本身更强为目标。若 RecA 只依赖离散图像词元的复制能力，那么它在 CLIP 这类连续语义表征上不应稳定提升；实验结果显示 CLIP 设置同样获益，说明重建对齐确实在改善理解表征到生成路径的语义传递。

A.3 掩码自回归生成范式

掩码自回归生成 (Masked Autoregressive Generation, MAR) 可以看作自回归建模和掩码建模之间的折中。它保留逐步生成的结构，但每一步不一定只预测单个词元，而可以预测一组词元或一个局部区域。这样既能利用自回归建模的序列化能力，又能降低纯 AR 在长图像序列上的效率问题。抽象地说，若把图像词元划分为若干组 $g_1, \dots, g_T$ ，则 MAR 可以写成

$$p_{\theta}(x) = \prod_{t=1}^T p_{\theta}(x_{g_t} | x_{g_{<t}}), \quad (\text{A-4})$$

其中每一组内部可以并行预测，组与组之间保持自回归依赖。

Harmon 采用 MAR 相关思想来协调理解与生成表示^[6,68]。它与 Show-o 的重要区别在于，Harmon 更强调共享视觉表示在理解和生成之间的协调，而不是仅

依赖离散 token 预测。第 4 章中 Harmon 的提升幅度较大，说明当模型本身已经试图共享理解和生成表征时，RecA 的重建目标可以进一步推动生成路径读取这些表征中的对象、颜色、位置和属性信息。

A.4 扩散与流匹配生成范式

扩散生成（Diffusion Generation）从噪声出发，通过多步去噪恢复图像。以去噪扩散概率模型（Denoising Diffusion Probabilistic Model, DDPM）为例，前向过程逐步向数据加入噪声：

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I), \quad (\text{A-5})$$

训练时模型学习预测噪声或去噪方向，常见目标为

$$\mathcal{L}_{\text{diff}} = \mathbb{E}_{x_0, t, \epsilon} [\|\epsilon - \epsilon_\theta(x_t, t, c)\|_2^2], \quad (\text{A-6})$$

其中 c 表示文本或视觉条件。扩散模型的优势是图像质量高、训练稳定，因此很多统一模型会把 MLLM 的理解表征接入扩散生成模块^[48,69]。

流匹配（Flow Matching）和校正流（Rectified Flow）则把生成过程看成从噪声分布到数据分布的连续变换，模型学习一个速度场 $v_\theta(x_t, t, c)$ ，使样本沿着该速度场从噪声移动到图像。一个常见目标可以写成

$$\mathcal{L}_{\text{flow}} = \mathbb{E}_{x_0, x_1, t} [\|v_\theta(x_t, t, c) - (x_1 - x_0)\|_2^2]. \quad (\text{A-7})$$

这类方法和扩散模型都属于连续空间生成路线，只是训练参数化和采样路径不同^[26-27]。

在本文实验中，OpenUni 属于连接式路线：它冻结预训练 MLLM，通过可学习查询把理解表征传递给扩散生成模块。MMaDA 则更接近把扩散式生成目标纳入多模态语言模型本身。BAGEL 也包含与连续视觉生成相关的模块，但其重点在于大规模统一预训练和 MoT 结构。对这些模型而言，RecA 不改变扩散或流匹配目标本身，而是让生成模块在去噪或速度场预测时更好地使用理解侧已经抽取的视觉语义。

A.5 与 RecA 的关系

上述范式的损失形式不同：AR 和掩码生成主要使用交叉熵，MAR 结合序列化和局部并行预测，扩散或流匹配使用连续空间的回归目标。但 RecA 的核心并不依赖某一种生成损失。它只要求统一多模态模型能够在某种条件下生成图像，然后把条件从稀疏文本替换为模型自身的视觉理解表征。也就是说，RecA 的重建目标可以写成统一形式：

$$\mathcal{L}_{\text{RecA}} = \mathcal{L}(f_{\theta}(\text{concat}(t_{\text{template}}, h_v)), I_{\text{gt}}), \quad (\text{A-8})$$

其中 $\mathcal{L}$ 可以是交叉熵、扩散损失或流匹配损失， h_v 是视觉理解编码器输出的表征， I_{gt} 是输入图像。这个统一形式解释了为什么第 4 章可以在 Show-o、Janus-Pro、Harmon、MMaDA、OpenUni 和 BAGEL 等不同模型上比较 RecA：这些模型的生成范式不同，但都存在同一个核心问题，即生成路径是否真正会使用理解路径中的视觉信息。

B 补充实验可视化

本节补充展示 RecA 在更多生成和编辑样例上的定性结果，以及正文表格之外的更多细分结果。这些结果用于辅助说明第 4 章中的跨模型实验、文生图实验和图像编辑实验。




图 B.1 RecA 的更多定性样例。




图 B.2 RecA 的更多文生图样例。Text prompt: A white banana and a black banana.



图 B.3 RecA 的更多文生图样例。Text prompt: A photo of a yellow broccoli.



图 B.4 RecA 的更多文生图样例。Text prompt: A photo of an orange snowboard and a green cat.



图 B.5 RecA 的更多文生图样例。Text prompt: A photo of a skis right of a zebra.



图 B.6 RecA 的更多文生图样例。Text prompt: A photo of a microwave and a truck.



图 B.7 RecA 的更多文生图样例。Text prompt: A diamond on the right, an emerald in the middle, a ruby on the left.




图 B.8 RecA 的更多文生图样例。Text prompt: Cheerful and bright, vibrant lighting. A shell and a bright orange bear in a bright setting.



图 B.9 RecA 的更多文生图样例。Text prompt: During the warm glow of a dwindling summer evening, a calico cat is perched atop a garden table, wearing large reflective aviator sunglasses, with blooming flowers and orange-pink sky in the background.



图 B.10 RecA 的更多文生图样例。Text prompt: A vivid scene where deep red tomatoes spill from a woven brown basket onto a rustic wooden tabletop, with green herb leaves and soft natural light from a kitchen window.



图 B.11 RecA 的更多文生图样例。Text prompt: A polished brown leather briefcase with visible stitching rests on a white tablecloth, beside a vibrant red fedora hat in a light beige room.



图 B.12 RecA 的更多文生图样例。Text prompt: A festive array of red and yellow balloons tied with curling ribbons, gently bobbing from the breeze of a spinning ceiling fan.




图 B.13 RecA 在 ImgEdit 上的更多图像编辑结果。




图 B.14 RecA 在 GEdit-Bench-EN 上的更多图像编辑结果。

作者简历

本科生毕业论文（设计）任务书

一、题目：统一多模态模型的重建对齐

二、指导教师对毕业论文（设计）的进度安排及任务要求：

1、进度安排

- (1) 2026 年 4 月 1 日至 2026 年 4 月 7 日：明确毕业论文选题和研究范围，查阅并整理相关文献资料，形成论文写作提纲和总体研究思路。
- (2) 2026 年 4 月 8 日至 2026 年 4 月 18 日：完成研究方案设计，梳理主要方法框架，确定实验内容、评价指标和论文各章节安排。
- (3) 2026 年 4 月 19 日至 2026 年 4 月 28 日：开展主要实验与结果整理，对实验现象进行分析，形成论文中方法介绍和实验分析部分的初稿。
- (4) 2026 年 4 月 29 日至 2026 年 5 月 6 日：完成论文全文撰写，检查论文结构、论证逻辑、图表呈现和参考文献格式，并根据指导意见进行修改。
- (5) 2026 年 5 月 7 日至 2026 年 5 月 10 日：完成论文定稿前的文字润色、格式检查和材料整理，按学校要求提交毕业论文。

2、任务要求

学生应在规定时间内独立完成毕业论文工作，围绕选题开展文献调研、方法整理、实验分析和论文写作。论文应做到研究目标明确、结构完整、论证清楚、图表规范、结论有依据；写作格式应符合浙江大学本科毕业论文要求，语言表达准确，参考文献引用规范，避免未经充分论证的结论。

起讫日期 2026 年 4 月 1 日至 2026 年 5 月 10 日

指导教师（签名）_____ 职称 _____

三、系或研究所审核意见：

负责人（签名）_____

年 月 日

本科生毕业论文（设计）考核

一、指导教师对毕业论文（设计）的评语：

指导教师（签名）_____

年 月 日

二、答辩小组对毕业论文（设计）的答辩评语及总评成绩：

成绩 比例	文献综述 (10%)	开题报告 (15%)	外文翻译 (5%)	毕业论文质量 及答辩 (70%)	总评 成绩
分值					

负责人（签名）_____

年 月 日